

分块质量验证结果

1.总块数与模型限制检查

- 总chunk数量： **3436** （来自2775篇有效文献）
- 未分割文献（b分支）： 2127篇，占76.6%，则与设计说明预估的76.1%基本吻合
- 分割文献（a分支）： 648篇
- 超过 bge-base-en- v1.5模型上限（512 token）的chunk数： **0**

结论：全部chunk均在embedding模型可接受范围，不需要进一步处理

2.文本质量

2.1 标题完整性

- source_title 缺失的chunk数: 0

2.2 截断检查

- 初步筛查：（looks_truncated_start，标点开头或小写字母开头，包含正常overlap延续的情况）： 开头疑似截断的chunk数（非首块）： 19 / 661
- 精确判定：（starts_with_stray_punct，仅统计孤立标点开头，即真正的切分错误）： 0 / 661
- 结尾疑似被截断的chunk数（非末块）： 2 / 661

总结：对比两项指标可知：初步筛查标记出的19条，经过二次拆分确认，全部属于"因overlap机制从句子中间开始、首字母小写"这一正常现象（starts_lowercase_midsentence: 19/661），不属于真正的切分错误。

发现与修复过程：初版分块脚本存在一处bug——RecursiveCharacterTextSplitter默认将分隔符（". "）保留在下一段开头，导致修复前精确判定（孤立标点）高达659/661的chunk开头出现孤立句点（如 . Results Vasectomy...）。

- 修复方式：在splitter配置中加入 keep_separator="end"，使分隔符保留在前一段结尾。修复后精确判定降至0/661，抽查确认句子边界恢复正常（如 chunk0结尾 ...in human bronchial fluid. / chunk1开头 The HFA-BDP formulated...）。

结尾疑似截断的2条为极少数样例，判断为末尾本来就缺少标点的正常文本，非分割问题。

3. 多块分割文献重点检查

3.1 结构一致性

- chunk_index不连续的文献数： 0
- total_chunks与实际块数不符的文献数： 0

结论：648篇被分割的文献，块序号完整连续，块总数标注准确，无漏块以及错标问题。

3.2 重叠部分检查

- 共检查661对相邻chunk
- 零重叠（实测重叠字符数为0）的chunk对数： 568 / 661（约86%）
- 重叠字符数分布：中位数为0，均值约17字符，最大150字符

导致零重叠过大的原因的排查过程

配置的chunk_overlap=80 tokens是理论上限，但实测86%的相邻chunk对未检测到重叠文本。对此依次验证了两个假设，均被数据推翻：

- 假设一：末句token数超出80-token重叠预算，分割器放弃重叠
抽样10条零重叠样例，实测chunk0末句token数集中在24-83，其中9条明显低于80的预算上限，仅1条压线超出。数据不支持"末句过长"是普遍原因，假设不成立。
- 假设二：检测方法过于严格（要求逐字符精确匹配）导致误判
改用宽松匹配（标准化空白后判断末句是否整体出现在下一chunk开头）重新检测同一批样本，结果9/10依然判定为"未重新出现"，仅1条（PMC549549）确认末句内容在chunk1开头重复出现。说明零重叠现象基本真实存在，不存在检测方法过严导致的误判。

但是需要重点排查（还未验证）：抽查零重叠样例时，发现一条比较特别的情况（doc_id=PMC516168）——chunk1不是从同一个段落下一句开始的，而是从小节标题Conclusions（结论）开始的，说明这个切分点正好卡在两个大段落（比如Results结果部分和Conclusions结论部分）的交界处。

因此会怀疑：也许分割器在跨章节的分界点上，会跳过重叠、不做过渡衔接，跟句子长短无关。

但目前只是看到了这一个例子，还没有专门去验证"是不是所有卡在章节交界处的chunk都零重叠"，所以这只是一个待确认的猜测方向，不能当作确定的原因写进结论里。

结论：零重叠现象真实存在且比例较高（约86%），但确切技术原因未能在本次排查中完全定位，需要进一步查阅RecursiveCharacterTextSplitter，暂不判断为影响chunk可用性的缺陷，但作为已知待澄清项记录在案，不排除后续需要重新评估分割策略的可能性。

4.总结

检查项	结果
超过模型token限制	0个chunk
标题缺失	0个chunk
开头截断（孤立标点）	0个chunk（已修复）
结尾截断	2个chunk（正常）
结构不一致（块序号/总数）	0篇文献
完整重叠达标率	约14%（86%零重叠，根因未完全定位，已排除"末句过长"和"检测误判"两个假设，见3.2）

本次分块结果整体质量良好：模型限制、标题完整性、结构一致性三项检查全部通过；已发现的一处切分bug（分隔符错位）已修复并验证。

重叠机制的低达标率是一个已确认但未完全定位根因的现象，已排除两个初步假设，不影响chunk本身的完整性，但后续可以跟进。