

本周进展：设备迁移 + 生成模块测试

这周做了什么

之前一直在8GB的Mac上开发，跑完整的四阶段生成流程（带审核那个）的时候GPU内存老是不够用，报"klOGPUCommandBufferCallbackErrorOutOfMemory"这个错，检索结果也会跟着乱掉，生成的答案有时候会把药认错。

这周主要在做两件事：把项目换到新设备上（24GB的Mac mini），然后重新跑了一遍测试，看看之前的内存问题是不是真的解决了。

迁移过程

搬过去的时候踩了个坑：05_multipath_retrieval.py 里之前为了图快写死了离线模式（HF_HUB_OFFLINE=1），结果新设备第一次跑，模型还没缓存到本地，离线模式又不让联网下载，两头堵死了报错。后来把这行注释掉才解决，这个改动这次也提交了。

其他环境配置（conda、Ollama、依赖包这些）也是重新装的，没什么特别的，就是花了点时间。

测试结果

用了5个关于metformin的问题测试，这次是精简版流程（没开critical review那个审核阶段），结果：

- **5条全部跑成功了**，没有一次崩溃或者报错
- **检索很快**，平均不到2秒
- **生成平均每条56秒左右**，5条总共花了4.9分钟
- **citation这块检查下来没有幻觉引用**，5条的PMC编号全部是真实存在的

内存这块确实是解决了，24GB完全够用，之前担心的OOM问题这次一次都没出现。

发现了一个新问题（比较重要）

第4条问题（老年人metformin用量）的回答里，中文部分把metformin写成了"甲磺酸西格列汀"——**这个其实是西格列汀（另一种降糖药，DPP-4抑制剂），跟metformin根本不是一类药**，属于翻译/识别错了。

这个跟之前记录过的"metformin被认成甲磺酸他汀"是一个性质的问题，说明中文输出这一步（final_assembler阶段）认药名这块不太稳，不是偶然一次的问题。

而且现在的检测逻辑（citation_check）只查PMC编号是不是真的存在，不会去查内容本身对不对，所以这种"引用是真的但内容说错了"的情况，现在的机制完全抓不出来，是个盲区。

顺便发现的小问题

5条里只有2条在正文里有夹着写 [PMC编号] 这种行内引用，另外3条只在最后列了个参考来源清单，正文没有具体标注是哪句话对应哪篇文献，看着不太好追溯。

提交记录

代码这次都提交到GitHub了（commit 5f13478），包括生成模块的10-12这三个脚本、05的那个bug修复、还有这次的测试日志。